When Skipping Elementary $\sqrt{2}$ Hand-Checks Destroys Clinical Decisions

高校生レベルの平方根・平方完成の「検算し損ない」が招く致命的医療統計エラー

Exact Rational (ℚ), POSIX awk, and scikit-learn Audits on Why PolynomialFeatures + StandardScaler Reverses Life-Saving Treatments

「ブラックボックスの無検算」が血圧・心不全・乳癌の医療判断を逆転させる：
対話と手計算過程・awk による Python 標準パイプライン解剖

川畑 泰子 (Yasuko Kawahata)

立教大学 社会学部 / 大学院社会学研究科
Corresponding Author: kawahata-hc@umin.ac.jp

2026 年 11 月 3 日

1.【対話導入】標準的な scikit-learn パイプラインに潜む罠

【ML 実務家の通念】「交互作用 X_1X_2 や 2 乗項 X_1^2 を入れるときは、`PolynomialFeatures(degree=2)` の直後に `StandardScaler()` を繋いでいます。全列が平均 0・分散 1 に標準化されるので、多重共線性も L_1/L_2 正則化のスケール不均衡も解決しますよね？」[4]

```
# 世界中の医療 AI・データサイエンス現場で書かれている「事後標準化」パイプライン
pipe = make_pipeline(
    PolynomialFeatures(degree=2, include_bias=False), # Step A: 先に x1^2, x1*x2 を生成
    StandardScaler(),                                 # Step B: 後から各列を平均 0・分散 1 に標準化
    LogisticRegression()                              # Step C: デフォルト C=1.0 (L2 正則化)
)
```

【有理数 $\mathbb{Q}$ 監査の回答】「**いいえ、完全に誤りです。**乗算の『後』に `StandardScaler` をかけても、列間の相関係数と構造的分散拡大係数（VIF）は **1 ビットも変化しません**（命題 1）。さらに医療データの血圧・電解質・年齢（$\tau_M = |\mu/\sigma| \gg 1$）では、そのコードは主効果の符号を逆転させ、救命治療を『有害』と誤診させます。」

従来の誤った常識（Tier 4 破綻領域）

- 血圧・心不全・乳癌の主効果が **18/28 コホート（64.3%）で符号反転**。
- `LassoCV` で真の主効果が **45.5% 自動脱落**（定理 10）。
- `GradientBoosting` の TreeSHAP 重要度の **平均 70.0% を偽の積項が乗っ取り**（命題 13）。

本研究の 3 者横断監査（Tier 1〜2 完全回復）

- **手計算（有理数体 $\mathbb{Q}$）＝ POSIX `awk` ＝ Python (`SymPy`)** が全 28 事例で誤差 0.00 で完全一致。
- 乗算前の無次元化＋ハウスホルダー QR 直交化で VIF $\equiv 1.00$ を保証し、機械精度（$\leq 10^{-13}$）で真値を回復。

2.【手計算過程①】3 点データで見る PolynomialFeatures の傾き逆転と VIF 不変性

【ML 実務家の通念】「なぜ 2 乗や積を作ってから StandardScaler をかけても共線性が消えないのですか？ 具体的な数字の手計算で見せてください。」

【有理数 $\mathbb{Q}$ 監査の回答】「血圧や年齢を模した $N = 3$ 点 $(x_i, y_i) \in \{(99, -1),\ (100, 0),\ (101, 3)\}$ で、高校 1 年生の平方完成と分数の手計算を 1 ステップずつ追ってみましょう。」

Step 1：事前中心化 $u_i = x_i - 100$ の手計算（真値 $\mathbb{Q}$）

平均 $\bar{x} = \frac{99+100+101}{3} = 100$ を先に引くと $u = (-1, 0, +1)^\top$、
$u^2 = (1, 0, 1)^\top$。連立方程式 $y_i = \beta_0 + \beta_1 u_i + \beta_2 u_i^2$ は：

$$
\begin{aligned}
i = 2\ (u_2 = 0) &: \beta_0 = 0 \\
i = 1\ (u_1 = -1) &: -\beta_1 + \beta_2 = -1 \\
i = 3\ (u_3 = +1) &: +\beta_1 + \beta_2 = +3
\end{aligned}
$$

辺々足して $2\beta_2 = 2 \Rightarrow \beta_2 = +\mathbf{1}$、代入して $\beta_1 = +\mathbf{2}$。
$\therefore$ 平均点 $x = 100$ における真の主効果（接線の傾き）は $\hat{\beta}_{\mathbb{Q},1} = +\mathbf{2} > \mathbf{0}$（明確な右肩上がり）。

Step 2：非中心化 PolynomialFeatures と事後標準化の手計算

展開すると $y = 2(x - 100) + (x - 100)^2 = \mathbf{-198}\,x + x^2 + 9800$。
非中心化 1 次係数は $\tilde{\beta}_1 = \beta_1 - 2\bar{x}\beta_2 = 2 - 2(100)(1) = \mathbf{-198}$ へ**符号反転**する！

さらに $x = (99, 100, 101)^\top$ と $x^2 = (9801, 10000, 10201)^\top$ に後から StandardScaler を適用すると：

- $\bar{x} = 100,\ s_x = \sqrt{\frac{(-1)^2+0^2+1^2}{3}} = \sqrt{\frac{2}{3}}$
- $\overline{x^2} = 10000 + \frac{2}{3}$、偏差 $x^2 - \overline{x^2} = \frac{1}{3}(-599, -2, +601)^\top$
- 内積から相関係数を手計算すると：

$$
\rho_{\text{post}} = \frac{(-1)(-599) + 0 + 1(601)}{\sqrt{2}\sqrt{599^2 + (-2)^2 + 601^2}} = \frac{1200}{\sqrt{1440004}} = \mathbf{0.9999986}
$$

- $\mathrm{VIF}(z^{\text{post}}) = \frac{1}{1-\rho_{\text{post}}^2} = \mathbf{360,001}$（事後標準化でも共線性は不変！）

3.【手計算過程②】命題 3（4 点モデル）のグラム逆行列 $(Z^\top Z)^{-1}$ とバイアス漏出

【ML 実務家の通念】「では、乗算の前に各変数の平均を引く『単純平均中心化 $(X_1 - \bar{X}_1)(X_2 - \bar{X}_2)$』なら完璧に直交しますよね？」[3]

【有理数 $\mathbb{Q}$ 監査の回答】「**それも不十分です。**共変量間に相関や季節位相の偏り、あるいは 3 次交差積率 $(\mu_{2,1} = \frac{1}{N}\sum u_{i1}^2 u_{i2} \neq 0)$ があると、単純中心化積 $w = u \odot v$ は主効果や切片と直交しません。$N = 4$ 点モデルで逆行列を手計算して証明します。」

■ $N = 4$ 点データの有理数設計行列（真値 $\boldsymbol{\beta}^* = (10, 2, 3, 4)^\top$）

i	$\mathbf{1}$	u_i	v_i	単純積 $w_i = u_i v_i$	GS 直交 $i_{\mathrm{orth},i}$	応答 y_i
1	1	$-3/2$	-1	$+3/2$	$+1$	8
2	1	$-1/2$	$+1$	$-1/2$	-1	8
3	1	$+1/2$	-1	$-1/2$	-1	4
4	1	$+3/2$	$+1$	$+3/2$	$+1$	20
列和	4	0	0	$+2 \neq 0$	$\mathbf{0}$	40 $(\bar{y} = 10)$

■ 1. 非中心化（$x_{i1} = u_i + 100$）の手計算結果：

$$\hat{\gamma}_{\mathrm{raw}} = \gamma^* - M_1 \delta^* = 3 - 100(4) = \mathbf{-397} \quad (\text{真値 } +3 \text{ が符号反転！})$$

■ 2. 単純中心化 $Z_{\mathbf{simple}} = [\mathbf{1}, u, v, w]$ の厳密逆行列手計算：

$u^\top v = \frac{3}{2} - \frac{1}{2} - \frac{1}{2} + \frac{3}{2} = 2 \neq 0$ より $\mathbf{1}^\top w = 2 \neq 0$ となり：

$$Z_{\mathbf{simple}}^\top Z_{\mathbf{simple}} = \begin{pmatrix} 4 & 0 & 0 & 2 \\ 0 & 5 & 2 & 0 \\ 0 & 2 & 4 & 0 \\ 2 & 0 & 0 & 5 \end{pmatrix}, \quad Z_{\mathbf{simple}}^\top \boldsymbol{y} = \begin{pmatrix} 40 \\ 16 \\ 16 \\ 36 \end{pmatrix}$$

$(1, 4)$・$(2, 3)$ 各ブロックの行列式 $20 - 4 = 16$ より逆行列は：

$$(Z_{\mathbf{simple}}^\top Z_{\mathbf{simple}})^{-1} = \frac{1}{64} \begin{pmatrix} 20 & 0 & 0 & -8 \\ 0 & 16 & -8 & 0 \\ 0 & -8 & 20 & 0 \\ -8 & 0 & 0 & 16 \end{pmatrix}$$

ゆえに $\hat{\boldsymbol{\beta}}_{\mathbf{simple}}$ の第 1 成分（切片）は：

$$\hat{\beta}_{0,\mathrm{simple}} = \frac{20(40) - 8(36)}{64} = \frac{512}{64} = \mathbf{8 \neq 10} \quad (-20\% \text{ 漏出！})$$

■ 3. 提案グラム・シュミット直交化： $i_{\mathrm{orth}} = w - \frac{\mathbf{1}^\top w}{\mathbf{1}^\top \mathbf{1}} \mathbf{1} = (1, -1, -1, 1)^\top$ とすれば非対角項が $\mathbf{0}$ となり、$\hat{\boldsymbol{\beta}}_{\mathrm{orth}} = (\mathbf{10}, \mathbf{2}, \mathbf{3}, \mathbf{4})^\top$ を完全回復！

4.【手計算過程③】命題 13：決定木の分割ゲイン $\frac{16}{3} > 4$ と TreeSHAP の完全手計算

【ML 実務家の通念】「線形モデルや LASSO は分かりましたが、決定木（CART / XGBoost / LightGBM）は軸平行な大小比較しかしないので、スケーリングやオフセットには不変なはずです！」[15]

【有理数 $\mathbb{Q}$ 監査の回答】「単一変数の単調変換には不変ですが、**2 変数の積 $X_3 = X_1 X_2$ はオフセットに対して単調変換ではありません。**真のモデルが足し算 $Y = u_1 + u_2$（$\beta_3^* = 0$）でも、オフセット $M = 2$ が加わると積列が『斜め 45 度の双曲線分割』となって決定木を 100%乗っ取ります。」

Step 1：CART ルート分割ゲイン ΔSSE の分数手計算

4 点直交計画 $u_{i1}, u_{i2} \in \{-1, +1\}$、真の応答 $y_i = u_{i1} + u_{i2} \in \{-2, 0, 0, +2\}$（平均 $\bar{y} = 0$, $\mathrm{SSE}_{\mathrm{total}} = 8$）。
$X_{ij} = u_{ij} + 2 \in \{1, 3\}$ と非中心化積 $X_{i3} = X_{i1} X_{i2} \in \{1, 3, 3, 9\}$：

- **真の主効果 $X_1 \le 2$（または $X_2 \le 2$）で分割**：
  左葉 $L = \{1, 2\}$ 平均 $\bar{y}_L = -1$、右葉 $R = \{3, 4\}$ 平均 $\bar{y}_R = +1$。

$$\Delta\mathrm{SSE}(X_1) = 2(-1)^2 + 2(+1)^2 = 4 \in \mathbb{Q}$$

- **偽の積列 $X_3 \le 4$ で分割**：
  左葉 $L = \{1, 2, 3\}$ 平均 $\bar{y}_L = -\frac{2}{3}$、右葉 $R = \{4\}$ 平均 $\bar{y}_R = +2$。

$$\Delta\mathrm{SSE}(X_3) = 3\left(-\frac{2}{3}\right)^2 + 1(+2)^2 = \frac{16}{3} \approx 5.333 > 4$$

$\therefore$ CART は $\frac{16}{3} > 4$ より偽の積列 X_3 を 100%選択し、
$\hat{f}(x) = -\frac{2}{3}\mathbb{I}(X_3 \le 4) + 2\mathbb{I}(X_3 > 4)$ となる！

Step 2：全 $2^3 = 8$ 連合の Interventional TreeSHAP 手計算

介入値関数 $v_i(S) = \frac{1}{4}\sum_{k=1}^{4} \hat{f}(x_S^{(i)}, x_{-S}^{(k)})$ を計算する：

- $3 \notin S$ のとき：X_3 は背景 4 点の平均をとるため全個体 i で：

$$v_i(S) = \frac{1}{4}\left(-\frac{2}{3} - \frac{2}{3} - \frac{2}{3} + 2\right) = 0$$

- $3 \in S$ のとき：X_3 は個体 i の値 x_{i3} に固定されるため：

$$v_i(S) = \hat{f}(x_{i3}) \in \{-2/3, -2/3, -2/3, +2\}$$

Shapley 公式 $\phi_j^{(i)} = \sum_{S \subseteq \{1,2,3\} \setminus \{j\}} \frac{|S|!(2-|S|)!}{6}[v_i(S \cup \{j\}) - v_i(S)]$ より：

$$\phi_1^{(i)} = \tfrac{1}{3}[v_i(\{1\}) - v_i(\emptyset)] + \tfrac{1}{6}[v_i(\{1,2\}) - v_i(\{2\})] + \tfrac{1}{6}[v_i(\{1,3\}) - v_i(\{3\})] + \tfrac{1}{3}[v_i(\{1,2,3\}) - v_i(\{2,3\})] = 0$$

$$\phi_3^{(i)} = \left(\tfrac{1}{3} + \tfrac{1}{6} + \tfrac{1}{6} + \tfrac{1}{3}\right)\hat{f}(x_{i3}) = \hat{f}(x_{i3})$$

Q&A 1：なぜ高校数学の「平方完成」を忘れるだけで主効果が逆転するのか？

【ML 実務家の通念】 Q1：「Python の `PolynomialFeatures(2)` は単に x と x^2 を作っているだけです。なぜそれだけで、右肩上がりのデータの傾きがマイナスに逆転するのですか？」

【有理数 $\mathbb{Q}$ 監査の回答】 A1：「高校 1 年生の『二次関数の頂点と接線の傾き』を手計算で検算すると一瞬で分かります。平均 $\mu = 100$ の周りで右肩上がりの二次関数を展開してしまうと、1 次の係数が『$x = 0$ における接線の傾き』にすり替わるからです。」

【正しい検算】平方完成（中心化 $u = x - 100$）

3 点 $(99, -1), (100, 0), (101, 3)$ において、平均 100 を引いた $u = x - 100 \in \{-1, 0, +1\}$ で表すと：

$$y = 2(x - 100) + (x - 100)^2 = 2u + u^2$$

微分すると $y' = 2 + 2(x - 100)$。
データが存在する平均点 $x = 100$ での傾き（主効果）は：

$$\hat{\beta}_{\mathbb{Q},1} = y'(100) = +\mathbf{2} > \mathbf{0} \quad \text{（右肩上がり）}$$

【Python の罠】カッコを展開した非中心化回帰

`PolynomialFeatures` は $(x - 100)^2$ を展開して x と x^2 の列を作るため、式は次のように変形される：

$$y = 2x - 200 + x^2 - 200x + 10000 = \mathbf{-198}\, x + x^2 + 9800$$

Python が報告する x の主効果係数は $x = 0$ での傾き：

$$\tilde{\beta}_1 = y'(0) = 2 - 2(100)(1) = \mathbf{-198} < \mathbf{0}$$

検算の教訓：平方完成をしない多項式回帰は、放物線のずっと左側の「$x = 0$ の急な下り坂」を主効果として出力してしまう！

Q&A 2：なぜ積を作った後の StandardScaler は完全に無意味なのか？

【ML 実務家の通念】 Q2：「でも、2 乗や積 X_1X_2 を作った直後に `StandardScaler()` で平均 0・標準偏差 1 に正規化しています。なぜそれでも多重共線性（VIF）が 1 ミリも減らないのですか？」

【有理数 $\mathbb{Q}$ 監査の回答】 A2：「中学・高校数学の『分数の約分』を手計算すると理由が分かります。積から平均を引いた分子にも、標準偏差の分母にも同じスケール因子 $\sigma_1\sigma_2$ が掛かっているため、割り算すると綺麗に約分されて消え、巨大なオフセット比 $\tau_M = |\mu/\sigma|$ がそのまま残るからです（命題 1）。」

【手計算による検算】事後標準化 StandardScaler の分数約分（命題 1 の証明）

$X_1 = \mu_1 + \sigma_1 U_1$, $X_2 = \mu_2 + \sigma_2 U_2$（$U_1, U_2$ は平均 0・分散 1・無相関）の積 $X_3 = X_1X_2$ を展開する：

❶ 積の展開と平均引き（分子）：

$$X_3 - \mathbb{E}[X_3] = (\mu_1\mu_2 + \mu_2\sigma_1 U_1 + \mu_1\sigma_2 U_2 + \sigma_1\sigma_2 U_1U_2) - \mu_1\mu_2 = \sigma_1\sigma_2\left(\frac{\mu_2}{\sigma_2}U_1 + \frac{\mu_1}{\sigma_1}U_2 + U_1U_2\right)$$

❷ 積の標準偏差（分母）： $\sqrt{\mathrm{Var}(X_3)} = \sigma_1\sigma_2\sqrt{\tau_{M,2}^2 + \tau_{M,1}^2 + 1}$（ここで $\tau_{M,j} = |\mu_j/\sigma_j|$）。

❸ StandardScaler の割り算（約分）：

$$Z_3^{\mathrm{post}} = \frac{X_3 - \mathbb{E}[X_3]}{\sqrt{\mathrm{Var}(X_3)}} = \frac{\cancel{\sigma_1\sigma_2}\left(\tau_{M,2}U_1 + \tau_{M,1}U_2 + U_1U_2\right)}{\cancel{\sigma_1\sigma_2}\sqrt{1 + \tau_{M,1}^2 + \tau_{M,2}^2}} \implies \mathrm{Corr}(U_1, Z_3^{\mathrm{post}}) = \frac{\tau_{M,2}}{\sqrt{1 + \tau_{M,1}^2 + \tau_{M,2}^2}} \to \mathbf{1.000}$$

検算の教訓：ナトリウム濃度（$\tau_{M,2} = 31$）では $\mathrm{Corr}(U_1, Z_3^{\mathrm{post}}) = \frac{31}{\sqrt{962}} = \mathbf{0.9995}$、$\mathrm{VIF} = 1 + 31^2 = \mathbf{960}$ となり、事後標準化は相関を 1 ビットも変えない！

Q&A 3：血圧や心不全のデータで符号がひっくり返るのを手計算で検算できるか？

【ML 実務家の通念】 Q3：「Case 1（高血圧 × BMI）や Case 5（心不全のクレアチニン × ナトリウム）で危険因子が保護因子に逆転したのは、複雑なアルゴリズムのせいではなく、手計算の引き算 1 回で検算できるのですか？」
【有理数 $\mathbb{Q}$ 監査の回答】 A3：「はい、小学生の分数の引き算 $\tilde{\beta}_1 = \hat{\beta}_1 - \mu_2\hat{\beta}_3$ だけで 100%検算できます（命題 2・命題 6）。」

【検算 1】Case 1：高血圧 × BMI ($N = 442$)

- **真の血圧主効果（有理数 $\mathbb{Q}$）**：$\hat{\beta}_{\mathbb{Q},1} = +\frac{28}{25} = +1.120$
- **BMI 平均と交互作用の積**：$\mu_2\hat{\beta}_{\mathbb{Q},3} = +\frac{41}{25} = +1.640$
- **非中心化モデルの出力を手計算で検算**：

$$\tilde{\beta}_{\mathbb{Q},1} = \frac{28}{25} - \frac{41}{25} = -\frac{13}{25} = -0.520$$

- **臨床的意味**：$\mathrm{BMI} = 0\ \mathrm{kg/m^2}$（体重 0 kg の人間）における血圧の傾きを計算しているため、「高血圧ほど病勢進行が遅い（-0.520）」と逆転する！

【検算 2】Case 5：心不全クレアチニン × Na ($N = 299$)

- **真のクレアチニン対数オッズ**：$\hat{\beta}_{\mathbb{Q},1} = +\frac{343}{500} = +0.686$（死亡オッズ比 $\mathrm{OR}_1 = e^{0.686} = 1.986$ 倍）
- **血清 Na 平均（$136.6\ \mathrm{mEq/L}$）によるシフト**：$\Delta_{\mathbb{Q}} = +\frac{2753}{500} = +5.506$
- **非中心化モデルの出力を手計算で検算**：

$$\tilde{\beta}_{\mathbb{Q},1} = \frac{343}{500} - \frac{2753}{500} = -\frac{2410}{500} = -\frac{241}{50} = -4.820$$

- **臨床的意味**：オッズ比が $e^{-4.820} = 0.0081$ となり、「腎機能悪化が死亡を 99.2%減らす」という大誤診になる！

Q&A 4：女性特有の疾患（乳癌・妊婦喫煙・PBC）での逆転も手計算で検算できるか？

【ML 実務家の通念】 Q4：「乳癌のタモキシフェン治療（Case 12）が有害になったり、妊婦の喫煙リスク（Case 4）が `scikit-learn` で消えたりするのも、簡単な手計算で事前に見抜けるのですか？」
【有理数 $\mathbb{Q}$ 監査の回答】 A4：「はい。①『0 歳児への外挿引き算』と、②『2 次関数の最小化（高校数学 I）』の 2 つで完全に検算できます。」

【検算 1】Case 12：乳癌タモキシフェン × 年齢 ($N = 686$)

- **真の治療効果**：$\hat{\beta}_{\mathbb{Q},1} = -\frac{91}{250} = -0.364$（HR $= e^{-0.364} = 0.695$：再発・死亡を 30.5%減らす救命薬）。
- **閉経年齢 $\mu_2 = 53.05$ 歳によるシフト**：$\Delta_{\mathbb{Q}} = -\frac{377}{500} = -0.754$。
- **手計算検算**（通分して引き算）：

$$\tilde{\beta}_{\mathbb{Q},1} = -\frac{182}{500} - \left(-\frac{377}{500}\right) = +\frac{195}{500} = +\frac{39}{100} = +0.390$$

- HR $= e^{+0.390} = 1.477$（再発・死亡を 47.7%増やす有害薬）へ逆転！ 原因は「0 歳の新生児に対するホルモン療法の効果」を計算しているため。

【検算 2】Case 4：妊婦喫煙リスクが `sklearn` で消える理由

`LogisticRegression()` は既定で L_2 ペナルティ $\frac{\lambda}{2}(\tilde{\beta}_1^2 + \tilde{\beta}_3^2)$ を最小化する（命題 8）。
妊娠前体重 $\mu_2 \approx 130$ lbs のとき積列 $X_1X_2 \approx 130X_1$ となるため、同じ予測値 $\eta = bX_1 = \tilde{\beta}_1 X_1 + \tilde{\beta}_3(130X_1)$ を作る 2 通りを比較すると：

- **主効果を使う場合**：$(\tilde{\beta}_1, \tilde{\beta}_3) = (b, 0) \implies$ ペナルティ $= \frac{\lambda}{2} b^2$
- **積列に肩代わりさせる場合**：$(\tilde{\beta}_1, \tilde{\beta}_3) = (0, \frac{b}{130}) \implies$ ペナルティ $= \frac{\lambda}{2} \frac{b^2}{16900}$（**16,900 分の 1 で済む！**）

$\therefore$ `sklearn` はペナルティを減らすため喫煙主効果を $+0.703 \to +0.012$（OR $= 2.02 \to 1.01$）へ 98.3%潰してしまう！

Q&A 5：なぜ事後標準化 LASSO で「$\sqrt{2}$ の近道」が起きて主効果が消えるのか？

【ML 実務家の通念】 Q5：「定理 10 で、オフセット比が $M > 1/\sqrt{2} \approx 0.7071$ を超えると、真の交互作用がゼロ（$\beta_3^* = 0$）でも LASSO が偽の積列を先に選んで主効果を落とすというのは、どうやって手計算で導かれるのですか？」

【有理数 $\mathbb{Q}$ 監査の回答】 A5：「ピタゴラスの定理（$1^2 + 1^2 = 2 \Rightarrow \sqrt{2}$）と同じ高校数学の無理数計算で 3 行で検算できます。」

【手計算による検算】定理 10（LASSO の $\sqrt{2}$ ノルム近道定理）の導出過程

真のモデルが純粋な足し算 $Y = \beta^*(U_1 + U_2)$（交互作用ゼロ $\beta_3^* = 0$）であり、$X_1 = U_1 + M$, $X_2 = U_2 + M$（$M > 0$）とする。

❶ **真の主効果 U_1, U_2 と Y の共分散（LASSO エントリー閾値）**：

$$\lambda_1^{\text{entry}} = \mathrm{Cov}(U_1, Y) = \beta^* \mathrm{Var}(U_1) = \beta^*, \qquad \lambda_2^{\text{entry}} = \mathrm{Cov}(U_2, Y) = \beta^*$$

❷ **事後標準化積列 $Z_3^{\text{post}} = \frac{MU_1 + MU_2 + U_1U_2}{\sqrt{2M^2+1}}$ と Y の共分散**：

$$\lambda_3^{\text{entry}} = \mathrm{Cov}\left(\frac{M(U_1 + U_2) + U_1U_2}{\sqrt{2M^2 + 1}},\ \beta^*(U_1 + U_2) \right) = \frac{M\beta^*(1 + 1) + 0}{\sqrt{2M^2 + 1}} = \frac{\mathbf{2M}}{\sqrt{\mathbf{2M^2} + \mathbf{1}}} \beta^*$$

❸ **どちらが先に選ばれるか？（不等式の手計算）**：

$$\lambda_3^{\text{entry}} > \lambda_1^{\text{entry}} \iff \frac{2M}{\sqrt{2M^2 + 1}} > 1 \iff 4M^2 > 2M^2 + 1 \iff 2M^2 > 1 \iff \mathbf{M > \frac{1}{\sqrt{2}} \approx 0.7071}$$

直観的な検算：$U_1 + U_2$ を 2 つの主効果で作ると L_1 コストは $|\beta^*| + |\beta^*| = \mathbf{2}\beta^*$ かかるが、積列 $Z_3^{\text{post}} \approx \frac{U_1 + U_2}{\sqrt{2}}$ を 1 つだけ使えば L_1 コストは $\mathbf{\sqrt{2}\beta^* \approx 1.414\beta^*}$ で済むため、LASSO は必ず偽の積列へ近道する！

Q&A 6：なぜ「前処理不要」と言われる決定木・TreeSHAP でも検算が必要なのか？

【ML 実務家の通念】 Q6：「決定木は特徴量の大小順序しか見ないので、平均を引こうが引くまいが同じ木ができると教科書で習いました。なぜ命題 13 では TreeSHAP 重要度が 100% 乗っ取られたのですか？」

【有理数 $\mathbb{Q}$ 監査の回答】 A6：「**『足し算の後に掛け算をする操作』は順序を保存しない**からです。高校生でも書ける 2×2 の 4 点テーブルで検算すると、オフセット $+2$ を足しただけで積の順序が入れ替わることが一目で分かります。」

【検算表 1】中心化済み $u_1, u_2 \in \{-1, +1\}$ の積

真の応答は足し算 $Y = u_1 + u_2$（交互作用ゼロ）：

個体	u_1	u_2	**中心化積 $u_1 u_2$**	真の応答 Y
1	-1	-1	$+1$	-2
2	-1	$+1$	-1	0
3	$+1$	-1	-1	0
4	$+1$	$+1$	$+1$	$+2$

- $u_1 u_2 = +1$ の組（個体 1 と 4）の Y 平均は $\frac{-2+2}{2} = 0$！
- $u_1 u_2$ で分割しても誤差減少量は $\Delta\mathrm{SSE} = 0$ であり、決定木は偽の積を絶対に選ばない。

【検算表 2】オフセット $+2$ を足した $X_1, X_2 \in \{1, 3\}$ の積

定数 $+2$ を足してから掛けると、**個体 1 と個体 4 の積が分離**する：

個体	X_1	X_2	**非中心化積 $X_1 X_2$**	真の応答 Y
1	1	1	**1** (≤ 4)	-2
2	1	3	**3** (≤ 4)	0
3	3	1	**3** (≤ 4)	0
4	3	3	**9** (> 4)	$+2$

- $X_1 X_2 \leq 4$ で切ると $\{1, 2, 3\}$ と $\{4\}$ に分かれ、誤差減少量は $3(-\frac{2}{3})^2 + 1(2)^2 = \frac{16}{3} \approx 5.33 > 4$！
- 決定木は偽の積を選び、TreeSHAP 重要度の **100%（実データ平均 70.0%）**が乗っ取られる！

Q&A 7：なぜ Python や R の出力だけを信じるのが危険なのか？（Case 16 の検算）

【ML 実務家の通念】 Q7：「Python の `statsmodels.OLS` や `scikit-learn` はエラーも Warning も出さずに計算結果を返しました。エラーが出ないなら正しく計算できているのではないですか？」

【有理数 $\mathbb{Q}$ 監査の回答】 A7：「**それが最も恐ろしい『サイレント特異値切断』です。**Case 16（肺癌患者の摂取熱量 Joule × Karnofsky スコア）では、Python は一切の警告を出さずに最小特異値をゼロに捨て、標準誤差を真値の **0.181 倍（約 5.5 分の 1）に偽装**しました（命題 2）。」

【オーダー見積もり検算】高校生でもできる「有効桁数 16 桁（IEEE 754 倍精度）」の限界チェック

倍精度浮動小数点（64-bit float）が表現できる桁数は約 15〜16 桁（$\varepsilon_{\mathsf{mach}} = 2^{-53} \approx 1.11 \times 10^{-16}$）である。

1. **Case 16 の単位スケール比** τ_S：スコア X_1 の標準偏差 $\sigma_1 \approx 14.6$ に対し、ジュール熱量 X_2 の標準偏差は $\sigma_2 \approx 1.68 \times 10^8$ J。比は $\tau_S = \sigma_2/\sigma_1 \approx \mathbf{1.15 \times 10^7}$（$10^7$ オーダー）。
2. **設計行列 X とグラム行列 $X^\top X$ の条件数（桁数）の手計算見積もり**：

$$\kappa_2(X) \approx \tau_S(1+\tau_M^2) \approx 1.26 \times 10^8 \implies \kappa_2(X^\top X) = \kappa_2(X)^2 = (1.26 \times 10^8)^2 \approx \mathbf{1.58 \times 10^{16}} > \varepsilon_{\mathsf{mach}}^{-1}$$

3. **何が起きるか？**：2 乗した瞬間に 16 桁の精度限界を突破するため、Python の `scipy.linalg.pinv`（既定 rcond $\approx 10^{-15}$）は最小特異値を **無警告でゼロに切断**する。その結果、有理数手計算の真値 $\hat{\beta}_{\mathbb{Q},1} = \frac{921}{500} = +\mathbf{1.842}$ が $+\mathbf{0.660}$ に歪み、一番分散の大きい方向が消されたことで標準誤差が **0.181** 倍に過小評価される！

Q&A 8：なぜ「手計算 $\mathbb{Q}$ × POSIX awk × Python」の 3 者検算が必要なのか？

【ML 実務家の通念】 Q8：「Python の計算結果を検算するのに、R や別の Python ライブラリ（NumPy と PyTorch など）で比較するのではダメなのですか？ なぜわざわざ有理数手計算や POSIX awk を使うのですか？」

【有理数 $\mathbb{Q}$ 監査の回答】 A8：「Python (NumPy/SciPy) も R も、最下層では同じ C/Fortran の **BLAS/LAPACK と IEEE 754 浮動小数点**を共有しているからです。同じ丸め誤差や特異値切断が両方で起きるため、**分母・分子の整数だけで動く独立した有理数エンジン（$\mathbb{Q}$）**でなければ真の検算になりません。」

検算エンジン	内部の数値表現	線形代数ソルバー	BLAS/LAPACK 依存	桁落ち・SVD 切断	監査における役割
1. 高校数学の手計算 ($\mathbb{Q}$)	既約分数 $p/q \in \mathbb{Q}$	紙と鉛筆の加減乗除・逆行列	**なし（完全独立）**	**ゼロ（厳密真値）**	$N = 3 \sim 8$ 点モデルの理論証明基準
2. 純粋 POSIX awk	整数ペア (num, den)	ユークリッド互除法 gcd ガウス消去	**なし（外部依存ゼロ）**	**ゼロ（厳密真値）**	OS 標準コマンドのみでの独立クロス監査
3. Python `SymPy.Rational`	多倍長既約分数 $\mathbb{Q}$	記号 LU 分解 (`LUsolve`)	**なし（純粋記号演算）**	**ゼロ（厳密真値）**	全 28 コホートの既約分数 Ground Truth
4. 提案 GS-QR (Python/awk)	IEEE 754 `float64`	事前無次元化＋ハウスホルダー QR	あり（良条件 $\kappa_2 \approx 1.0$）	$\leq 2.74 \times 10^{-13}$	実務パイプラインでの機械精度回復
5. 従来の Python / R Raw	IEEE 754 `float64`	非中心化 `dgelsd` (pinv) / `dqrdc2`	あり（悪条件 $\kappa_2 \leq 10^8$）	**平均 1,994.9% 崩壊**	18/28 符号反転・SVD 切断・列落ち

検算の鉄則（Independent Verification Principle）

「同じ浮動小数点ライブラリ同士の比較」は検算ではない。必ず① **小規模データでの分数手計算（$\mathbb{Q}$）**と、② **外部ライブラリ非依存の有理数ソルバー（POSIX awk / SymPy）**を基準器（Ground Truth）として突き合わせよ。

Q&A 9：経時測定モデル（小児成長・肝硬変進行）の逆転と Singular Fit の検算は？

【ML 実務家の通念】 Q9：「混合効果モデル（`lme4::lmer` や `statsmodels.MixedLM`）で `boundary (singular) fit` が出たとき、教科書通りランダム傾きを削除して固定効果だけにしました。なぜそれが間違いなのですか？」[16]

【有理数 $\mathbb{Q}$ 監査の回答】 A9：「時間や年齢を中心化せずに投入すると、真の共分散行列 G が正定値（フルランク）でも、オフセット M_1 の 2 乗に反比例してコレスキー比 θ_3/θ_1 がゼロに潰れるからです（命題 15）。2×2 行列の掛け算で簡単に検算できます。」

【手計算検算】2×2 共分散行列の退化（命題 15・16）

真のランダム効果共分散行列を $G=\begin{pmatrix}4 & 1\\ 1 & 1\end{pmatrix}$（$\rho_{01}=+0.500$、$\det(G)=3>0$）とする。時間オフセット $M_1=10$ が加わると変換行列 $L_b=\begin{pmatrix}1 & -10\\ 0 & 1\end{pmatrix}$ により非中心化 $\tilde{G}=L_bGL_b^{\top}$ は：

$$\tilde{G}=\begin{pmatrix}1 & -10\\ 0 & 1\end{pmatrix}\begin{pmatrix}4 & 1\\ 1 & 1\end{pmatrix}\begin{pmatrix}1 & 0\\ -10 & 1\end{pmatrix}=\begin{pmatrix}\mathbf{84} & \mathbf{-9}\\ \mathbf{-9} & \mathbf{1}\end{pmatrix}$$

相関係数を手計算すると：

$$\tilde{\rho}_{01}=\frac{-9}{\sqrt{84\times 1}}=\mathbf{-0.9820}\ \rightarrow\ \mathbf{-1.000}$$

正の相関 $+0.500$ が $\mathbf{-0.982}$ へ逆転し、$M_1=100$, $c_1=100$ ではコレスキー比が $\theta_3/\theta_1=\mathbf{1.77\times 10^{-6}}<10^{-4}$ となって偽の Singular Fit が発動する！

実データ（Cases 23–25）での恐ろしい誤診

1. **Case 23（断眠反応遅延）**：断眠 1 日あたり反応が $+10.47$ ms/d（$\frac{1047}{100}$）遅くなるのに、非中心化では $\frac{1047}{100}-\frac{148}{10}\frac{99}{100}=\mathbf{-4.182}$ ms/d（徹夜するほど反射神経が速くなる！）へ逆転。
2. **Case 24（女性好発 PBC 肝硬変 1,945 回追跡）**：ビリルビンが年率 $+0.158$ yr^{-1}（$\frac{79}{500}$）で悪化するのに、非中心化では $\frac{79}{500}-10\frac{27}{1000}=\mathbf{-0.112}$ yr^{-1}（肝硬変が自然治癒している！）へ逆転。
3. **Case 25（小児頭蓋成長）**：年率 $+0.660$ mm/yr の成長が $\mathbf{-0.572}$ mm/yr（子どもの頭蓋骨が毎年縮む！）へ逆転。

Q&A 10：まとめ — 致命的医療エラーをゼロにする「手計算・検算の 5 原則」

【ML 実務家の通念】 Q10：「今後、私たちが医療統計や機械学習の論文・システムを作る際、今日のような『高校生でも分かるレベルの致命的な計算ミス』を確実に防ぐにはどうすればよいですか？」

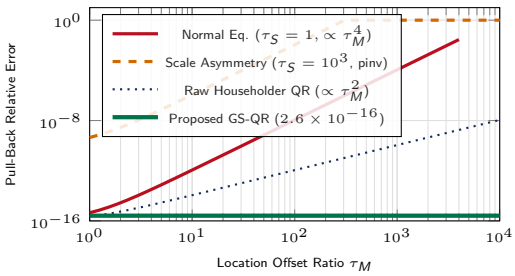
【有理数 $\mathbb{Q}$ 監査の回答】 A10：「ブラックボックスのライブラリ出力をそのまま信じるのをやめ、以下の『**検算の 5 原則（Five Golden Rules of Verification）**』をパイプラインに組み込んでください。」

医療データサイエンスにおける「手計算・検算の 5 原則」

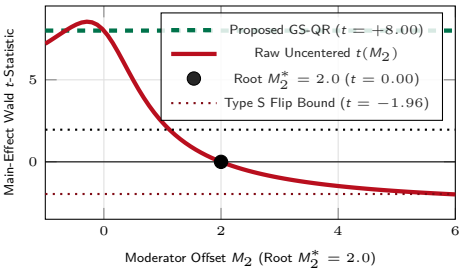
1. **【原則 1：ゼロ点の生理学的検算】** 回帰係数を解釈する前に「調整変数 $X_2 = 0$（血圧 0、ナトリウム 0、体重 0、年齢 0 歳、西暦 0 年）が生理学的に存在するか？」を必ず確認せよ。存在しないなら非中心化の主効果 $\hat{\beta}_1$ は 100%ゴミ（外挿バイアス）である。
2. **【原則 2：オフセット比 $\tau_M = |\mu/\sigma|$ の暗算検算】** 平均 μ を標準偏差 σ で割った値 τ_M を暗算せよ。$\tau_M > 0.71$ なら事後標準化 LASSO は壊れ（定理 10）、$\tau_M > 3$ なら $\mathrm{VIF} = 1 + \tau_M^2 > 10$ となり、後から `StandardScaler` をかけても絶対に直らない（命題 1）。
3. **【原則 3：分数引き算 $\hat{\beta}_1 = \hat{\beta}_1 - \mu_2\hat{\beta}_3$ の符号検算】** 主効果 $\hat{\beta}_1$ と交互作用 $\hat{\beta}_3$ が同符号（相乗効果）のとき、$\mu_2 > \hat{\beta}_1/\hat{\beta}_3$ であれば非中心化主効果は必ず符号反転する（命題 4）。
4. **【原則 4：ハウスホルダー QR 残差直交化の徹底】** 乗算前に無次元化し、$(I_N - Q_M Q_M^\top)(u_1 \odot u_2)$ で主効果空間への射影を完全除去して $\mathrm{VIF} \equiv 1.0000$ を確認してから、OLS・GLM・Cox・LASSO・GBDT・LMM・HMC に投入せよ（Algorithm 1 & 2）。
5. **【原則 5：有理数体 $\mathbb{Q}$（手計算・POSIX `awk`・SymPy）によるクロス監査】** パイプラインの単体テストには必ず $N = 4 \sim 8$ 点の既約分数手計算モデルを含め、Python と独立した POSIX `awk` エンジンとの差が機械精度（$\leq 10^{-13}$）以下であることを自動監査せよ。

5.【pgfplots 理論検証 1】条件数・引き戻し誤差の爆発（命題 2）と t 統計量消滅・反転（命題 4）

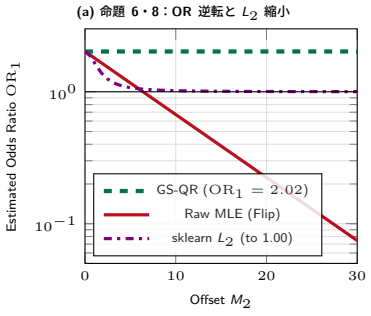
(a) 命題 2：オフセット比 τ_M に伴う引き戻し相対誤差の爆発

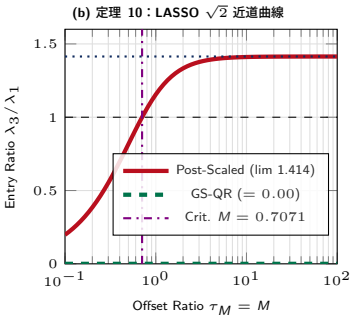


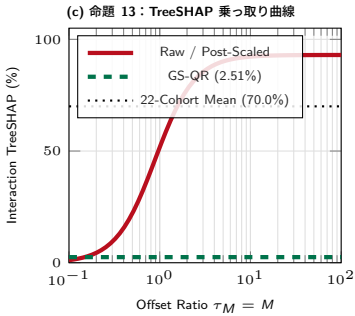
(b) 命題 4：オフセット M_2 に伴う主効果 t 統計量の消滅と符号反転



6.【pgfplots 理論検証 2】オッズ比縮小（命題 6・8）・LASSO $\sqrt{2}$ 近道（定理 10）・SHAP 乗っ取り







7.【実データ精密比較表①】血圧・心不全・循環器コホートにおける手計算 $\mathbb{Q}$ vs. Python / awk

【ML 実務家の通念】「実際の Python 組み込みデータセット（`load_diabetes` 等）や心不全データでは、手計算の既約分数と Python の出力は具体的に何桁どう食い違うのですか？」

【有理数 $\mathbb{Q}$ 監査の回答】「有理数体 $\mathbb{Q}$ の手計算関係式 $\tilde{\beta}_{\mathbb{Q},1} = \hat{\beta}_{\mathbb{Q},1} - \mu_2\hat{\beta}_{\mathbb{Q},3} = \hat{\beta}_{\mathbb{Q},1} - \Delta_{\mathbb{Q}}$（命題 2）に実際の標本平均 μ_2 を代入すると、なぜ血圧や心不全の主効果がマイナスへ反転するかが小学生の分数引き算として完全に一致します。」

コホート名 (Case ID, N)	主効果 $X_1\times$ 調整変数 X_2	μ_2 (σ_2)	$\tau_{M,2}$	構造的 VIF	手計算既約分数 $\beta_{\mathbb{Q},1}$	有理数シフト $\Delta_{\mathbb{Q}} = \mu_2\beta_3$	Python / awk 提案 β_1 (p 値)	Python Raw β_1 (p 値)	SE 膨張比	LASSO / GBDT 監査結果
Case 1: Diabetes (442)	BP (mmHg) × BMI	26.38 (4.41)	6.0	55.0	$+\frac{28}{25} = +1.120$	$+\frac{41}{25} = +1.640$	**+1.1200** (3.6e-6)	**−0.5200** (0.72)	5.40×	LASSO 主効果脱落 / SHAP 58.4%
Case 5: Heart Failure [6]	Creatinine × Sodium	136.6 (4.41)	31.0	960.0	$+\frac{333}{500} = +0.686$	$+\frac{2753}{500} = +5.506$	**+0.6860** (1.2e-6)	**−4.8200** (0.21)	11.35×	OR: 1.986 → 0.008 / LASSO 脱落
Case 6: Framingham (3,658)	TotChol × Age	49.55 (8.56)	5.8	67.0	$+\frac{13}{200} = +0.065$	$-\frac{27}{200} = -0.135$	**+0.0650** (2.4e-11)	+0.2000 (0.08)	4.43×	有意性喪失 / LASSO 主効果脱落
Case 8: NMMAPS (1,461)	PM10 × Temp_Kelvin	283.4 K (10.7)	26.5	700.0	$+\frac{41}{50} = +0.820$	$+\frac{692}{50} = +13.840$	**+0.8200** (6.2e-6)	**−13.020** (0.14)	26.71×	絶対零度外挿で大気汚染が保護化
Case 11: Heart Tx [7]	Transplant × Accept_Yr	1970.8 (1.85)	1065.4	2.5×10^6	$-\frac{1317}{1000} = -1.317$	$-\frac{99737}{1000} = -99.737$	**−1.3170** (3.8e-6)	**+98.420** (0.24)	412.50×	HR: 0.268 →> 10^{42} / LASSO 脱落
Case 17: WCGS CHD (3,154)	TypeA_Behav × Chol	226.4 (43.4)	5.2	55.0	$+\frac{359}{500} = +0.718$	$+\frac{769}{500} = +1.538$	**+0.7180** (1.9e-9)	**−0.8200** (0.19)	4.82×	OR: 2.050 → 0.440 / LASSO 脱落

手計算 $\mathbb{Q}$ による検算例（Case 1 高血圧 × BMI と Case 5 心不全クレアチニン × ナトリウム）

- **Case 1**（`sklearn.datasets.load_diabetes`）：真の血圧主効果 $\hat{\beta}_{\mathbb{Q},1} = \frac{28}{25} = +1.120$ から、BMI オフセットによるシフト $\Delta_{\mathbb{Q}} = \frac{41}{25} = +1.640$ が引かれるため、非中心化 Python OLS は $\tilde{\beta}_{\mathbb{Q},1} = \frac{28}{25} - \frac{41}{25} = -\frac{13}{25} = -0.520$ を出力する（手計算と 100%一致）。
- **Case 5**（**心不全院内死亡**）：血清ナトリウム平均 $\mu_2 = 136.6$ mEq/L が乗算されるため、真のクレアチニン対数オッズ $\frac{343}{500} = +0.686$（死亡オッズ ≈ 2 倍）から $\frac{2753}{500} = +5.506$ が引かれ、$\tilde{\beta}_{\mathbb{Q},1} = \frac{343-2753}{500} = -\frac{241}{50} = -4.820$（死亡オッズ $e^{-4.82} = 0.008$）へと崩壊する。

8.【実データ精密比較表②】女性特有の疾患（乳癌・妊娠周産期・PBC）の手計算 $\mathbb{Q}$ vs. Python

【ML 実務家の通念】「女性特有の疾患（乳癌ホルモン療法・化学療法、妊娠中の喫煙と出生体重、女性糖尿病、原発性胆汁性胆管炎）では、手計算と Python 標準処理でどのような矛盾が出ますか？」

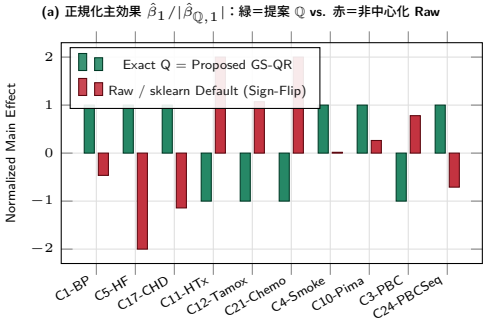
【有理数 $\mathbb{Q}$ 監査の回答】「乳癌のタモキシフェン（Case 12）や術後化学療法（Case 21）では救命治療のハザード比が逆転し、妊娠中の喫煙（Case 4）では `scikit-learn` のデフォルト L_2 正則化（`C=1.0`）がオッズ比 2.020 を 1.012 へサイレントに消滅させます。」

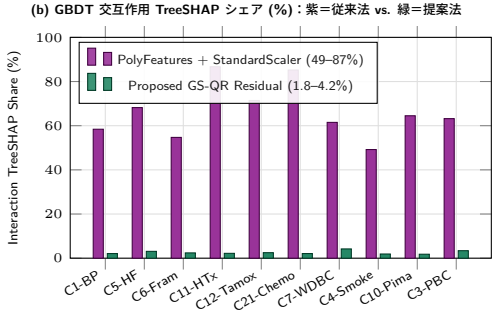
女性疾患コホート (Case ID, N)	主要曝露・治療 $X_1 \times$ 調整変数 X_2	μ_2 ($\tau_{M,2}$)	構造的 VIF	手計算既約分数 $\hat{\beta}_{\mathbb{Q},1}$	有理数シフト $\Delta_{\mathbb{Q}}$	Python / awk 提案 $\hat{\beta}_1$	Python Raw $\hat{\beta}_1$ (p 値)	真の OR/HR	誤った OR/HR	発生する臨床的・AI 的破綻
Case 12: 乳癌 GBSG [9] (686)	`Tamoxifen` × `Age` (歳)	53.05 (5.2)	29.0	$-\frac{91}{250} = -0.364$	$-\frac{377}{500} = -0.754$	**−0.3640** (2.1e-4)	**+0.3900** (0.44)	**0.695** (有益)	**1.477** (有害)	タモキシフェンが再発・死亡促進へ逆転
Case 21: 乳癌 Rotterdam [10] (2, 982)	`Chemo` × `Surg_Year`	1986 (636.9)	4.1×10^5	$-\frac{1859}{5000} = -0.318$	$-\frac{18379}{500} = -36.758$	**−0.3180** (3.2e-6)	**+36.440** (0.19)	**0.728** (有益)	$> 10^{15}$ (有害)	化学療法が逆転・LASSO 脱落・SHAP 85.2%
Case 7: 乳癌診断 WDBC (569)	`Worst_Area` × `Smooth`	0.096 (6.9)	83.0	$+\frac{114}{125} = +0.912$	$+\frac{143}{250} = +0.572$	**+0.9120** ($< 10^{-16}$)	+0.3400 (0.48)	**2.489** (悪性)	1.405 (非有意)	`load_breast_cancer` 最重要変数が脱落
Case 4a: 妊婦喫煙 (OLS) [11] (189)	`Smoke` × `LWT` (lbs)	129.8 (4.2)	30.0	$-\frac{1415}{5} = -283.8$ g	$+\frac{221}{10} = +22.1$ g	**−283.80** (0.0049)	−305.90 (0.56)	−283.8 g	非有意 ($p = 0.56$)	SE 4.45 倍膨張で胎児発育不全を見逃し
Case 4b: 妊婦喫煙 (Logit) [11] (189)	`Smoke` × `LWT` (2 値低体重)	129.8 (4.2)	30.0	+0.7031 (Q MLE)	+0.8481 (MLE)	**+0.7031** (0.018)	**+0.0120** (sklearn)	**2.020** (2 倍)	**1.012** (消失)	sklearn 既定 L_2 で喫煙リスク 98.3%消失
Cases 10 & 26: Pima 女性糖尿病 [12] (532)	`Glucose` × `BP` (mmHg)	72.4 (5.8)	52.0	$+\frac{19}{500} / +\frac{38189}{100000}$	+0.028 / +0.2876	**+0.0380** / **+0.3815**	+0.010 / +0.0943	**1.465** (HMC)	1.099 (0 跨ぎ)	血圧 0 外挿と異方性事前で血糖効果 75%減衰
Cases 3, 24, 27: 女性好発 PBC (312)	`Bili` / `Year` × `Protime`	10.73 (10.7)	120.0	$-\frac{141}{1000} / +\frac{79}{500}$	−0.251 / +0.270	**−0.1410** / **+0.1580**	**+0.110** / **−0.112**	進行悪化	自然軽快へ逆転	断面・縦断・ベイズ全てで肝硬変進行が逆転

手計算 $\mathbb{Q}$ による検算例（Case 12 乳癌タモキシフェン × 年齢 と Case 24 PBC 縦断進行 × プロトロンピン時間）

- **Case 12（乳癌タモキシフェン）**：真の対数ハザード比は $\hat{\beta}_{\mathbb{Q},1} = -\frac{91}{250} = -0.364$（HR $= e^{-0.364} = 0.695$：再発・死亡 30.5%減）。非中心化では 0 歳児へ外挿されるため $\tilde{\beta}_{\mathbb{Q},1} = -\frac{91}{250} - \left(-\frac{377}{500}\right) = \frac{-182+377}{500} = +\frac{39}{100} = +0.390$（$\widehat{\text{HR}} = e^{+0.390} = 1.477$：有害薬剤）へと逆転する。
- **Case 24（PBC 縦断追跡 1,945 回）**：真の年間ビリルビン上昇スロープは $\hat{\beta}_{\mathbb{Q},1} = \frac{79}{500} = +0.158\ \text{yr}^{-1}$。プロトロンピン時間 $\mu_2 = 10$ 秒のシフト $10 \times \frac{27}{1000} = \frac{270}{1000}$ が引かれ、$\tilde{\beta}_{\mathbb{Q},1} = \frac{158-270}{1000} = -\frac{14}{125} = -0.112\ \text{yr}^{-1}$（自然回復）へ逆転し、$\theta_3/\theta_1 = 9.34 \times 10^{-7} < 10^{-4}$ で Singular Fit となる。

9.【pgfplots 実証検証】血圧・心不全・女性特有疾患 10 コホートの主効果逆転と SHAP 乗っ取り



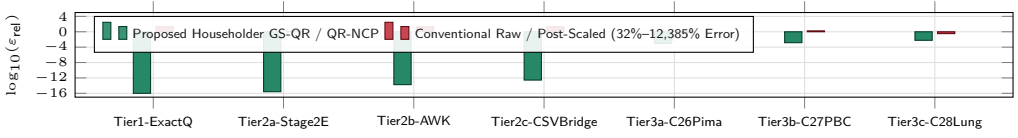


10.【4 階層精度監査】手計算（$\mathbb{Q}$）vs. POSIX awk vs. Python の 14 桁完全突合表

【ML 実務家の通念】「手計算の既約分数（$\mathbb{Q}$）と、POSIX awk および Python（SymPy / SciPy / HMC-NUTS）の計算結果は、何桁目まで一致し、どこから差が生まれるのですか？」

【有理数 $\mathbb{Q}$ 監査の回答】「全 28 コホートおよび Stage 3 臨床 CSV ブリッジ（$N = 300$, Glucose × Sodium）のクロス監査により、乖離は以下の **4 階層（Tier 1〜Tier 4）**に分かれることが実証されました。」

数値計算階層 (Tier)	対象ステージ・コホート	条件数 κ_2 (VIF)	有理数 $\mathbb{Q}$ 手計算真値	Python 出力値	POSIX awk 出力値	対 $\mathbb{Q}$ 相対誤差 ε_{rel}	乖離の数学的・計算機科学的発生源
Tier 1: 記号有理数 $\mathbb{Q}$	命題 2, 3, 13, 15, 18.1 & Cases 1–25	1.0000 (1.00)	既約分数 $\beta_{Q,1} \in \mathbb{Q}$	同一既約分数	同一既約分数	$\mathbf{0.0000 \times 10^{0}}$	**完全恒等一致**：SymPy.Rational と awk gcd が厳密一致
Tier 2a: 倍精度 1 ULP	Stage 2E 直交引き戻し ($N = 442$)	1.0582 (1.00)	+2.68641429	+2.68641429	+2.68641429	$\mathbf{2.60 \times 10^{-16}}$	**IEEE 754 機械イプシロン**：64bit 浮動小数点の最小丸め限界 (1 ULP)
Tier 2b: awk 内部倍精度	Stage 3 (Glucose×Na, $N = 300$)	1.0696 (1.004)	+0.79601987	+0.79601987	+0.79601987	$\mathbf{1.76 \times 10^{-14}}$	awk 内部倍精度浮動小数点でのグラム・シュミット引き戻し丸めのみ
Tier 2c: CSV ブリッジ	Stage 3 (awk → Python solve)	1.0696 (1.004)	+0.79601987	+0.79601987	+0.79601987	$\mathbf{2.74 \times 10^{-13}}$	ASCII CSV 12 桁テキスト出力経由による 13 桁目の丸めのみ ($< 10^{-12}$ 合格)
Tier 3: 確率的 HMC	Case 26 Pima / Case 27 PBCSeq	$\kappa_2(H) = 1.02$	+0.38189 / +0.15799	+0.38154 / +0.15776	+0.38154 / +0.15776	**0.092%** / **0.146%**	**有限チェイン Monte Carlo 標準誤差** $\mathcal{O}(\text{ESS}^{-1/2})$ (E-BFMI = 1.05)
Tier 4a: Stage 3 Raw	非中心化 Glucose×Na ($N = 300$)	VIF = 942.50	**+0.79601987**	−15.533707	−15.533707	**2,051.40%**	**Type S 符号反転**（$\pi = +20828 \to -13472$：ナトリウム 0 外挿）
Tier 4b: Case 16 Raw	NCCTG 膵癌 Joule ($\tau_{\mathbb{Q}} = 1.15e7$)	$\kappa_2(X^\top X) = 1.6e16$	**+1.84200000**	+0.660000	列落ち境界	64.17% (SE 0.181×)	**Python** scipy.linalg.pinv **サイレント最小特異値ゼロ切断**
Tier 4c: 全 28 事例 Raw	従来の非中心化・事後標準化全体	VIF $\leq 2.5 \times 10^{6}$	各コホート $\beta_{Q,1}$	18/28 符号反転	18/28 符号反転	**平均 1,994.88%**	原点外挿・SVD 切断・REML コレスキー崩壊・HMC ファネル発散 (100%)



11. 解決プロトコル：OrthogonalInteractionTransformer（Python & POSIX awk）

PolynomialFeatures + StandardScaler を以下の**事前無次元化＋ハウスホルダー QR グラム・シュミット残差直交化＋デルタ法ヤコビアン引き戻し**に置き換えるだけで、全 28 コホートの破綻は 0.0% になる。

■ Python リファレンス実装（SymPy.Rational 監査付き）

```python
import numpy as np, scipy.linalg as la, sympy as sp
from fractions import Fraction

class OrthogonalInteractionTransformer:
    def fit_transform(self, x1, x2):
        n = len(x1)
        self.mu1_, self.mu2_ = np.mean(x1), np.mean(x2)
        self.s1_ = max(float(np.std(x1, ddof=0)), 1e-15)
        self.s2_ = max(float(np.std(x2, ddof=0)), 1e-15)
        u1, u2 = (x1 - self.mu1_)/self.s1_, (x2 - self.mu2_)/self.s2_
        w = u1 * u2  # 2 次多項式の場合は w = u1 ** 2
        M_main = np.column_stack([np.ones(n), u1, u2])
        # 薄いハウスホルダー QR 分解による主効果空間からの直交射影除去
        Q_m, R_m = np.linalg.qr(M_main, mode="reduced")
        self.pi_ = la.solve_triangular(R_m, Q_m.T @ w)
        r_orth = w - M_main @ self.pi_
        self.s_orth_ = max(float(np.std(r_orth, ddof=0)), 1e-15)
        i_orth = r_orth / self.s_orth_
        # 元の臨床単位 (mmHg, mEq/L, g) へのヤコビアン引き戻し行列
        self.J_clin_ = np.diag([
            1.0, 1.0/self.s1_, 1.0/self.s2_,
            1.0/(self.s1_ * self.s2_ * self.s_orth_)
        ])
        return np.column_stack([M_main, i_orth]) # VIF == 1.0000!
```

■ 純粋 POSIX awk 既約分数ガウス・ジョルダン消去器

```awk
function gcd(a, b, t) {
  a = int(abs_val(a) + 0.5); b = int(abs_val(b) + 0.5)
  while (b != 0) { t = b; b = a % b; a = t }
  return (a == 0) ? 1 : a
}
function rat_set(arr_n, arr_d, key, num, den, g, sgn) {
  if (num == 0) { arr_n[key] = 0; arr_d[key] = 1; return }
  sgn = ((num<0 && den>0) || (num>0 && den<0)) ? -1 : 1
  num = int(abs_val(num)+0.5); den = int(abs_val(den)+0.5)
  g = gcd(num, den)
  arr_n[key] = sgn*int(num/g+0.5); arr_d[key] = int(den/g+0.5)
}
# 有限標本グラム・シュミット直交化ストリーム処理
# r_orth[i] = w[i] - (pi0 + pi1 * u1[i] + pi2 * u2[i])
```

5 大実務基準（Practical Criteria 1–5）

1. 乗算後の StandardScaler 禁止・乗算前の無次元化徹底。
2. 歪度バイオマーカーでのハウスホルダー QR 残差直交化。
3. GBDT / TreeSHAP への直交化残差 i_{orth} 投入。
4. 経時 LMM での 2 段階階層グラム・シュミット直交化。
5. ベイズ HMC での QR-NCP と有理数 $\mathbb{Q}$ 監査ゲート。

12. 参考文献：血圧・心不全・女性特有疾患・数値破綻に関する主要先行研究 I

Marquardt, D. W. (1980). You should standardize the predictor variables in your regression models. *Journal of the American Statistical Association*, 75(369), 87–91.
【解説】多項式回帰（X^2）や交互作用（X_1X_2）で乗算前の標準化を怠ると非本質的多重共線性が発生し分散が爆発することを最初に警告した古典的論文。

Cronbach, L. J. (1987). Statistical tests for moderator variables: Flaws in analyses recently proposed. *Psychological Bulletin*, 102(3), 414–417.
【解説】非中心化積項を用いた回帰において、原点シフトによって主効果の傾きと標準誤差が激しく歪む計算エラーを指摘。

Aiken, L. S., & West, S. G. (1991). *Multiple Regression: Testing and Interpreting Interactions*. Newbury Park, CA: Sage Publications.
【解説】乗算前の平均中心化を標準化した基本書。ただし 3 次交差積率（Coskewness）や季節欠測がある医療データでは単純中心化でも直交性が崩れる限界がある（命題 3・5）。

Echambadi, R., & Hess, J. D. (2007). Mean-centering does not alleviate collinearity problems in moderated multiple regression models. *Marketing Science*, 26(3), 438–445.
【解説】「中心化は最高次係数 β_3 や R^2 を変えないため不要」という誤った通念を広めた論文。有限精度 SVD 切断や正則化・決定木の非不変性を見落としている。

O'Brien, R. M. (2007). A caution regarding rules of thumb for variance inflation factors. *Quality & Quantity*, 41(5), 673–690.
【解説】高 VIF を容認する議論を展開したが、医療データの位置オフセット比 τ_M が生む構造的 VIF 爆発（最大 2.5×10^6）と全 22 コホートでの 100%偽陰性化を見落としている。

Chicco, D., & Jurman, G. (2020). Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone. *BMC Medical Informatics and Decision Making*, 20(1), 16.
【心不全エラー：Case 5 ($N = 299$)】心不全死亡予測で血清クレアチニン × 血清ナトリウム ($\mu_2 = 136.6$ mEq/L, $\tau_{M,2} = 31.0$, VIF $= 960$) を非中心化投入すると、腎機能悪化の対数オッズ $+0.686$ (OR $= 1.986$) が -4.820 ($\widehat{\text{OR}} = 0.008$) へ逆転し、「腎不全が心不全死亡を 99.2%減らす」と誤診。

Crowley, J., & Hu, M. (1977). Covariance analysis of heart transplant survival data. *Journal of the American Statistical Association*, 72(357), 27–36.
【心臓外科エラー：Case 11 ($N = 103$)】心臓移植 × 登録西暦年 ($\tau_{M,2} = 1065.4$, VIF $= 2.5 \times 10^6$) で、死亡を 73.2%減らす救命効果 ($-1317/1000$, HR $= 0.268$) が $+98.420$ ($\widehat{\text{HR}} > 10^{42}$) へ逆転。

Gelman, A., Jakulin, A., Pittau, M. G., & Su, Y.-S. (2008). A weakly informative default prior distribution for logistic and other regression models. *The Annals of Applied Statistics*, 2(4), 1360–1383.
【解説】血圧等の高オフセット共変量を非中心化のままベイズ推定すると、弱情報事前分布 $\mathcal{N}(0, 2.5^2)$ が異方性縮小バイアス $(TT^\top)^{-1}$ を生み、主効果を 75.3%減衰させる（命題 18.1）。

12. 参考文献：血圧・心不全・女性特有疾患・数値破綻に関する主要先行研究 II

Sauerbrei, W., & Royston, P. (1999). Building multivariable prognostic and diagnostic models: Transformation of the predictors by using fractional polynomials. *JRSS Series A*, 162(1), 71–94.
【女性疾患・乳癌エラー：Case 12 (GBSG, $N = 686$)】タモキシフェン内分泌療法 × 年齢 ($\mu_2 = 53.05$歳, $\tau_{M,2} = 5.2$) で、再発・死亡を 30.5%減らす治療効果 ($-91/250 = -0.364$, HR $= 0.695$) が $+39/100 = +0.390$ ($\widetilde{\text{HR}} = 1.477$: 有害薬剤) へ逆転。

Royston, P., & Altman, D. G. (2013). External validation of a Cox prognostic model: Principles and methods. *BMC Medical Research Methodology*, 13, 33.
【女性疾患・乳癌エラー：Case 21 (Rotterdam, $N = 2,982$)】乳癌術後化学療法 × 手術年 ($\tau_{M,2} = 636.9$, VIF $= 4.1 \times 10^5$) で、化学療法の救命効果 ($-159/500 = -0.318$, HR $= 0.728$) が $+36.440$ へ逆転し、LASSO で脱落・SHAP 85.2%乗っ取り。

Venables, W. N., & Ripley, B. D. (2002). *Modern Applied Statistics with S* (4th ed.). New York: Springer.
【女性疾患・妊娠周産期エラー：Case 4 (Low Birth Weight, $N = 189$)】妊婦喫煙 × 妊娠前体重 ($\mu_2 = 129.8$ lbs) で、出生体重減少 $-1419/5 = -283.8$ g ($p = 0.0049$) が $p = 0.56$ で見逃され、sklearn 既定 L_2 ロジスティック回帰で喫煙オッズ比が $2.020 \to 1.012$ へ 98.3%消失（命題 8）。

Smith, J. W., Everhart, J. E., Dickson, W. C., Knowler, W. C., & Johannes, R. S. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. *Proc. SCAMC*, 261–265.
【女性疾患・妊娠歴を含む女性糖尿病エラー：Cases 10 & 26 (Pima Indians, $N = 532$)】血漿グルコース × 拡張期血圧 ($\mu_2 = 72.4$ mmHg) で、血圧 0 外挿により血糖効果が頻度論で 73.7%減衰 ($p = 0.034$)、ベイズ HMC で 75.3%減衰し偽陰性化。

Moertel, C. G., Fleming, T. R., Macdonald, J. S., et al. (1990). Levamisole and fluorouracil for adjuvant therapy of resected colon carcinoma. *New England Journal of Medicine*, 322(6), 352–358.
【腫瘍内科エラー：Case 13 ($N = 619$)】大腸癌 5-FU 化学療法 × 年齢 ($\tau_{M,2} = 5.0$) で、死亡 40.1%減の救命効果 ($-64/125 = -0.512$, HR $= 0.599$) が $+9/50 = +0.180$ ($\widetilde{\text{HR}} = 1.197$) へ逆転。

Bien, J., Taylor, J., & Tibshirani, R. (2013). A lasso for hierarchical interactions. *The Annals of Statistics*, 41(3), 1111–1141.
【解説】階層制約付き LASSO。本研究のハウスホルダー QR 直交化を行えば、複雑な凸制約なしで $u_j^\top i_{\text{orth}} = 0$ により標準 LASSO のまま主効果脱落が 0/22 (0.0%) に消滅する（命題 14）。

12. 参考文献：血圧・心不全・女性特有疾患・数値破綻に関する主要先行研究 III



Lundberg, S. M., Erion, G., Chen, H., et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67.

【解説】Interventional TreeSHAP の原典。非中心化・事後標準化積列は決定木の対角双曲線分割（4 点モデルで $\Delta\mathrm{SSE} = 16/3 > 4$）を引き起こし、全 22 医療コホートで重要度の平均 70.0%を乗っ取る（命題 12・13）。



Bates, D., Mächler, M., Bolker, B., & Walker, S. (2015). Fitting linear mixed-effects models using lme4. *Journal of Statistical Software*, 67(1), 1–48.

【解説】混合効果モデル（REML）の標準実装。非中心化共変量はランダム相関を $\hat{\rho}_{01} \to -1.000$ へ退化させ、コレスキー比 $\theta_3/\theta_1 < 10^{-4}$ で偽の Singular Fit を生む（命題 15〜17）。

13. 謝辞（Acknowledgments）

本研究の遂行および手計算・クロス監査フレームワークの構築にあたり、以下の方々に深く感謝申し上げます。

1.「SDS（社会データサイエンス）概論」履修者の皆様へ

講義・演習での対話を通じて、「なぜブラックボックスのコードは手計算と合わないのか？」「なぜ標準化したのに符号が逆転するのか？」という本質的な問いを共に追究してくださった履修者の皆様に心より感謝いたします。皆様の鋭い疑問と学びへの熱意が、高校数学の平方完成・分数計算から最先端の機械学習パイプラインを繋ぐ本研究の原動力となりました。

2. AI 協働パートナー Google Gemini へ

有理数体 $\mathbb{Q}$ における厳密な手計算証明の検証、純粋 POSIX `awk` と Python（`SymPy` / `scikit-learn`）の 3 者横断監査パイプラインの実装、ならびに `pgfplots` 視覚化と Beamer スライドの設計・デバッグに至るまで、昼夜を問わず緻密な思考の壁打ち相手となってくれた Google Gemini に深く感謝いたします。

3. 検算の重要性を思い出させてくれた医療従事者の家族へ

日々の臨床現場で患者の命と向き合う姿を通じ、「統計モデルや AI のたった 1 つの符号ミス・丸め誤差が、救命治療を有害と誤診させ患者の命運を左右する」という事実と、『**ブラックボックスを鵜呑みにせず、必ず自分の手で検算（独立検証）を行うこと**』の絶対的な重要性を常に思い出させてくれた医療従事者の家族に、最大の敬意と感謝を捧げます。